

# 小芽：宠物对战游戏里的 LLM 教练

## 设计与实现说明

腾讯 IEG 面试题提交稿 2026 年 9 月

本报告由 AI 辅助撰写，全部数据与结论由本人核实。正文引用的每个数字都对应仓库里一份可复现的产物；结论、失败与未完成项经本人逐条核对后写入，没有实测过的部分，文中直接写明没测过。

## 1 题目与取舍

这道题要求为宠物对战游戏做一个 AI 教练，具备军师、陪练、老师三种角色感，参考方向列了 Agentic RL、RAG、ReAct、Memory Stream / Reflection，产品参考是和平精英的「小田」与王者荣耀的「灵宝」。我的理解是：交付物是教练，游戏只是产生局面的环境；三种角色感不是三种语气，而是三种不同的正确性标准——军师要判断准确且可解释，老师只能依据当时可见的信息，陪练要记得住并且不越界。

第一个动作是划边界，而不是写代码。三件事本次不做：**美术与完整游戏内容**，规模控制在 14 只宠物、7 种属性、5 个关卡，这个量已经足够产生「抢先收尾还是留能量」「换宠承伤还是原地治疗」这类真实取舍；**联网 PVP**，本地对战是同机分屏，双方各自锁定行动后一起结算，服务端仍然接受客户端传来的状态快照，不是权威对局服务，这条差距是架构问题而不是工程量问题；**主模型的权重训练**——没有微调过 DeepSeek，线上规划与改写一直用基座模型；这个项目的重心是 agent 侧的工程，工具调用、检索、记忆、验收，训练不在其中，本机没有可用的 CUDA 后端只是顺带的事实。后来补做的只有两个离线小实验（一个小型工具路由头、一个干预时机策略），它们不在产品链路里，第五节单独交代。

三种角色我全部做完了，题目要求的是至少闭环一项。它们的难点并不重叠：军师的难点在分工，老师的难点在时间口径，陪练的难点在克制；只做一种，后两类问题不会暴露出来。

## 2 交付了什么

**军师**。引擎枚举双方全部合法行动，对每一种组合跑一遍共享结算器，模型只负责把算好的事实讲成玩家能理解的取舍；双方同速时两种出手顺序各算一次，搜索不会偷偷利用随机数。局内主动提示也归军师：触发条件是代码里的五条——伙伴倒下、在两个选项间来回犹豫、真实枚举出来的明显策略错误、长停留、血量低于 35% 而背包里还有药。「安静档」是玩家自己设的档位：教练不主动开口，只在被问时回答，它不是关闭教练而是改成被动；它和「本局不再提醒」优先于上面任何一条触发条件。

图 1 里展开的那一块是这条提示的计算依据：双方当前血量与能量，以及它引用的两张知识卡。依据里的数字全部来自引擎枚举，模型只写最上面那句话；展开区不复述折叠时那句结论，所以同一句话不会在一屏上出现两遍。




图 1 军师提示条与它展开的计算依据

**陪练。**它的重点是陪伴，三件事都有交付：**闲聊**能在玩家只说「你好」时接住话头；**情绪**能表达，但必须落在真实事件上；**历史与偏好**记得住——连败几局、最近赢没赢、上一局打到第几回合、还剩几瓶药、本命是哪只、上次玩是几天前，以及玩家声明过的偏好与目标。这些字段决定它用哪一档语气，档位本身会写进模型输入的证据里，所以它说出的每句话都能回溯到一条本机记录。它在场：对局中间会自己插一句看法，不提问、不给指令。情绪的边界是这一版专门改过的：允许说的是有落点的态度——**AFFECTS**只有五个词：可惜、漂亮、悬、憋屈、松口气，每一个都必须绑在一条真实读数上，比如「连着 3 局没赢。比上一局多撑了 1 个回合，最后还是没翻过来，可惜。」或者「第 15 回合收掉，这一局拿得漂亮。」（两句都是引擎实跑出来的输出）。反过来，第一人称的感受一律拦下：「我看得有点急」这样的句子在旧版里出现过，它把玩家变成了来看 AI 着急的旁观者，现在由 **SELF\_CENTERED\_EMOTION** 在出句后扫描；**SCREEN\_ECHO** 则挡掉「被草系按着打」这类玩家自己看得见的事。两条判据合起来是「情绪只能在事件上，不能在它自己身上」。




图 2 陪练气泡：不打开聊天也能看见

如图 2，气泡在战斗页左下角，独立于聊天面板：不打开聊天也能看见它，可以点掉，点掉之后本局静音。每局主动搭话有上限，最近七天的关闭次数会降低这个上限，四次之后直接归零。它不评价玩家水平、不给战术指令、不说教，这三条由 **checkCompanionRestraint** 在出句后扫描。

## 2.1 老师

老师不只是复盘。它盯着玩家看哪一个技能不动就讲哪一个：属性、能耗、算在当前目标身上多少伤害、打完剩几豆、什么条件下比手里别的选项更合适，但不催出招。每回合结束给这一回合的事实；整局结束给复盘，从减员和生命变化里挑三个回合逐个分析。小测按真实面板出变式题（「速度 38 加一次敏捷 +3，对速度 41 的先手还是后手，还是无法确定」），选项里带「不确定」。培养建议是它唯一涉及成长的入口，给出加点收益与这次加点是否改变先手关系。

图 3 是整局结束后的复盘：上面一行是这局的结论，展开区是它挑出来的关键回合与对比数据。整局统计只讲发生过的行动，没换宠、没用道具就不提；回合记录里的内




图 3 老师的整局复盘与挑出来的关键回合

部标识与原始统计对象都不进玩家文案。

真正花心思的是教学账本。它记三件事：讲过哪一课、哪一课被标回未掌握、这一课有几个被提示过和没被提示过的行动。讲过又没有新反证就不重复；只有军师在局内独立观察到三次同类失误（RELEARN：至少 3 次行动、合理率低于 50%）才标回未掌握，并能说出「这一课教过，但之后 4 次独立行动里有 3 次不合理」。重新讲过就消费掉，再教要靠新出现的独立失误。

培养建议会摊开三项数值的对照，比如加 1 点力量后攻击从 27 到 31。这里有一个容易踩的坑：讲 assistance dilemma 的那篇论文报告，他们早期的预测器没把「学生用过提示」算进去，而提示本身会把学生推向高效步骤，用过的学生反而被判成「不需要帮助」；修正就是把两者分开。小芽里是同一件事：判断玩家是否掌握某个知识点时，只用他没有被提示过的时候做出的选择。

复盘一律使用回合开始时的公开状态，不使用对手实际打出的那一招——否则任何一次失败都能被解释成「你当时选错了」。改掉对手的实际行动，复盘结论不变，这条有测试。

这套账本是自建的计数与规则，不是心理测量模型：只判断教过没有、这次要不要再教，不估计掌握概率。

## 2.2 游戏本体

营地练级与配招、出征选关选人、局内逐回合出招，三段构成一局（图 4）。顶部两个入口：训练按关卡挑战固定对手，对局里对手自由配队，也可以是同机分屏的两名真人，两边各有一条教练。



(a) 培养面板：经验、升级与三项加点



(b) 配招：6 选 4 与携带物

图 4 营地的养成与配招面板

出征分两步：先选关卡（图 5 左），再按选择顺序挑三只伙伴（右），阵容建议由教练给出。



(a) 出征第一步：关卡选择与关卡信息



(b) 出征第二步：按顺序挑三只伙伴，右侧是阵容建议

图 5 出征：两步选关选人

`npm start` (Node.js 20+, 无第三方依赖) 之后浏览器打开本地端口即可。不接模型也能完整游玩，规则建议、复盘、培养建议和小测都不依赖模型；接入模型之后，这些解释改由模型生成。密钥只留在后端进程内存里，不落盘。

语音、联网 PVP、依赖真人被试的验收都没做完，逐条写在第五节。

### 3 协作与验收

使用子 agent 并行实现，我负责架构、验收与关键修复。全项目出现最多的一类问题是：代码看着对、测试全绿、功能根本没有生效——下面四个实例都不是读代码发现的，只有实际跑起来才看得见。

- 服务端漏了静态资源白名单里的新模块 `rules.js`，`/rules.js` 返回 404，`app.js` 的 `import` 图整体失败，页面元素没有渲染出来。
- 陪练的 `notify()` 写完了，全仓库没有调用点：主动气泡从不出现（后来补上了调用点）。
- 军师里留了一个未定义变量，每秒抛一次 `ReferenceError`，浏览器日志里攒了 75 条。
- 敌方补位「决定了却无人提交」：换宠选好、存进变量就返回，玩家那条路径又拒绝替它提交，界面永久冻结在「正在出招…」。

验收因此换成两层检查。第一层是 `wiring.test.js`：`app.js` 里每个 `$( 'id' )` 都要在 `index.html` 或 `app.js` 自建的元素里存在，死函数清单必须恰好是两个已知遗留，面试题要求的每项能力都必须找得到入口；它第一次运行就抓出一处指向已删除元素的残留引用。第二层是冒烟测试：无头浏览器真打一局，断言营地渲染出伙伴卡、对局打到结果、控制台零报错；它不进 `npm test`，因为需要浏览器的检查不该当成必过门；它也有假阳性，一次报「最长连续无可点 14 次」，查下去是动画播放期间按钮本来就被禁用。

#### 3.1 检查本身也要被检查

术语检查写出来之后，我做了负向验证：把禁止词表里的词植入一句玩家可达的文案，测试必须失败；移除，测试必须通过。这一步暴露出一个原本看不出来的缺口——检查取局内提示时没有传事件参数，「明显策略错误」那条理由的正文根本不在覆盖范围内；第一次修补也错了，手工造一个事件参数传进去，负向验证立刻戳穿。最后换成静态扫描，逐行取 `coach/` 下的中文字面量对词表，不依赖运行时路径，随即又扫出四处真泄漏。

## 3.2 代码是对的，错的是统计


有一处缺陷代码完全正常，错的是统计口径：玩家补位的那一回合本来就不该出招，却被计成一次「引擎兜底」，方向恰好让对手 agent 显得比实际更差；同类的一处是犹豫判定用了墙钟时间，玩家中途去操作对方面板的 13 秒被算成「犹豫了 13 秒」。这类错误不会让任何测试失败，只能靠逐条核对分子分母才能发现。另一类更容易漏：交付里写下的「某方案没用」往往只对了一半——检索实验里最好的一臂确实没有显著赢过基线，但拆开四条臂能看到排序指标确实变好了。

## 4 实现中的难点

这一节的主线是把「算」和「说」分开：引擎负责对，模型负责讲。下面几个取舍都是这条主线的推论，也都是我改错过的地方。

### 4.1 一条执行链，和它每一步的成色

三种角色共用同一条链：玩家提问、或代码判定该开口时，请求先过门控，再由有界的工具循环去查证，查到的回执必须过校验，最后才允许输出——或者允许沉默。



链上七步逐条核过，依据都在仓库里：触发不来自请求层——玩家提问走聊天面板，自动触发由 app.js 的事件钩子与 coach/experience.js 的触发层判定（每局上限、理由去重、冷却都在这一层），coach/client.js 只做请求调度与超时降级；门控在 policy.js，循环、校验与输出上限都在 runtime.js，工具与参数契约在 toolbox.js，证据来自 engine.js 的合法行动枚举与 strategist.js 的 93 张知识卡，记忆写在 memory.js。记忆与反思这一环要把两件事分开说：规则与证据驱动的 Reflection 已实现——同类独立行动满 3 条时，rememberDecision 写下掌握判断（带证据 id 与依据），它真的改变行为：adaptiveGate 据此降频，observeStruggle 与 markUnlearned 据此重教；LLM 自动总结式 Reflection 未做，Generative Agents 式的自由合成不在这一版里。还有一处必须说准，否则会把单工具记录包装成多步 Agent：有界循环已实现，并由确定性 planner 测试验证，但真实模型评测中还没有观察到多工具链——44 条既有真实记录的调用次数分布是 {0:36, 1:8}，本轮又补跑 4 条不同问法的用例，全部不超过 1 次。

### 4.2 记忆里的结论必须能被撤回

掌握判断不是模型写的，是本机按证据写的：同一课攒够 3 条独立行动才落一条判断，每条判断带着它依据的事件 id。证据一旦不在记录里，引用它的结论就一起失效——玩家删掉一条证据会撤回对应判断，组装上下文时也会把证据不足 3 条的判断整条丢掉（runtime.js），所以它宁可说「还没有足够的独立行动证据」，也不拿一条证据

已经不在的判断去评价玩家。

### 4.3 数字不能让模型算

第一版我让模型看着局面直接给建议，回答里的数字稳定地错：编出不存在的技能名，算错伤害，在两个都能击倒的技能里挑面板数字大的那个。改法是把职责切开：引擎枚举，模型解释。

同一个残血目标，火花直接伤害 52，追猎 75，两者都够击倒，都耗 2 点能量。只看面板，很自然会建议选追猎。但这是错的：追猎的额外伤害来自「目标已灼烧」这个前提，对方吃药、换宠、防御都会让前提失效。这种判断交给模型是猜，交给枚举是算。

切开之后还剩两类数字校验抓不到的错。第一类是道具名：游戏里只有回复药、净化药、能量果三样，模型会把净化药说成「解药」、能量果说成「以太」——数字全对，引用全对，只有名字是错的，因为没有数字可校验。第二类是因果：伙伴倒下时，它这一回合已经排好的行动会被取消，模型会把这次取消描述成「命中了」。两类都靠新增检查解决：一份别名黑名单，命中即判不合格；读回合事件，某个行动被记为取消时，正文里就不能出现它造成了伤害。



(a) 行动面板：每个技能都带引擎算好的威力与能耗



(b) 战况：双方血量、能量、备战席与剩余道具

图 6 对局界面：行动面板与战况

图 6 的两张分别是行动面板与战况，军师那句解释允许引用的只有这两处和战斗记录里的东西。

最后一类更隐蔽：模型读到的规则本身是旧的。原来的属性相克表不对称，我换成两个独立的三环；军师、经验层、规则页从同一张表读，自动跟着走了，但把规则抄成自然语言的副本不会。改掉手写的那张边界卡之后，扫第二遍才发现六张脚本生成的属性卡里仍是旧数值——它们正是检索喂给模型的地面事实：教练会照着一张引擎已不再实现的规则回答，而测试全绿，因为没有测试盯这句话。根因是那句话在生成脚本里硬编码，这一轮改成从规则对象取数。这类副本我手工找漏了三次。

### 4.4 「该不该调工具」不该由模型决定

工具决策我做过三轮真实评测，同一套 44 条预注册用例，全部真实 API 调用，变差的那一轮也保留。三轮依次改的是：原始提示词；把「默认停止」写进提示词并点名哪几类必须调；给模型加一个「必须调用」的字段。第三轮已回退。

第 2 轮不是纯改善：多余调用从 75.0% 降到 33.3%，漏调却从 0 升到 21.9%。第 3

| 指标      | 第 1 轮   | 第 2 轮   | 第 3 轮   |
|---------|---------|---------|---------|
| 多余工具调用率 | 75.0%   | 33.3%   | 13.6%   |
| 漏调率     | 0.0%    | 21.9%   | 77.3%   |
| 严格正确率   | 31.25%  | 50.0%   | 31.8%   |
| 模型自停率   | 3.23%   | 96.8%   | —       |
| 延迟 p50  | 4284 ms | 2798 ms | 2154 ms |

轮更差：我加那个字段本意是补上三类硬需求，实际等于告诉模型「这个字段是空就不必调」，而它在大多数用例上都是空的。

三轮的摆动说明问题不在措辞，在分工。数据给出的分界很清楚：模型**选哪个工具**很准（第 2 轮在「预期应调且确实调了」的 12 条上是 12/12），但**判断该不该调**只有一半正确。所以第 4 轮不是继续改提示词，而是把政策写进代码：证据包里已经带着当前局面和最近回合事件，问当前状态的不用再查，只有结构上不含的四类才需要查；判定需要时由代码直接执行第一步，再问模型要不要继续，判定不需要时整个工具循环跳过。

44 条里只有 32 条可判定，每格 1 条、单次运行，上表所有差值都没有置信区间；即使第 2 轮，严格正确率也只有 50%。而且这 50% 里有一部分不是模型错——预注册标准认为「我这只还剩多少血」应该调一次读状态，但证据包里本来就带着当前局面，第 2 轮那 7 条漏调里有 6 条属于这一类，是两种政策的差异。产品必须选一个并说清楚，我选了「包里已有的事实不重复取」。

#### 4.5 检索没有赢过关键词

我的假设是：在词项检索之上再加一层领域概念扩展，口语化提问的命中率会提高。为了验证它，我建了一个四臂对照：不检索；词项检索（中文二元词项加权 + IDF）；词项加领域概念扩展；以及一个把反例文本提为一等字段的第四臂。128 条查询（112 条有正解、16 条越界），离线跑，不调用模型。

四臂都是本机可查的词项方法，**没有一个用到向量**——领域概念扩展是一份可审阅的领域词表，不是预训练 embedding。仓库里另有一个真正的多语言向量检索实现（Python 侧 `semantic-worker.py`，用 `model.encode` 编码知识卡），它不在这组 128 条实验里，两者的数据集与实现都不同，不能混在一张表里比较。

| 臂           | Hit@3         | MRR           | 负例拒答        |
|-------------|---------------|---------------|-------------|
| 不检索         | 0.00%         | 0.0000        | 16/16（平凡结果） |
| 纯关键词（现默认）   | 88.39%        | 0.8007        | 9/16        |
| 词项 + 领域概念扩展 | 90.18%        | 0.7996        | 9/16        |
| 反例字段加权      | <b>91.07%</b> | <b>0.8244</b> | 9/16        |

结果是没有任何一个臂显著赢过关键词基线。最好的一臂只高 2.68 个百分点（112 条正解里 5 胜 2 负），McNemar 精确检验  $p = 0.4531$ ，配对 bootstrap 95% 置信区间  $[-1.79, +7.14]$  个百分点，跨零。

我差点在这儿犯错：看到扩展没赢，第一反应是「检索没用，RAG 是伪需求」。拆开四臂才发现不是——第四臂的 MRR 从 0.8007 升到 0.8244，排序确实变好，只是改

善都发生在 112 条正解上。最后我记成「这次测量没测出差别」，既没换成向量检索，也没宣称 RAG 无效。

真正被这轮测出来的是负例拒答：三个检索臂都只有 9/16，越界提问仍然召回了卡片，原因是词项检索只要命中任意二元组就判为正分，没有最低分阈值，也没有拒答机制。这是尚未解决的问题，调权重解决不了。另外，这 128 条查询和标注都由我完成，不是独立盲标集：沿用的 20 条旧查询 Hit@3 是 81.25%，新写的 92 条是 93.48%，说明出题时我已知道卡片里有哪些词，所有绝对数字都偏乐观。

#### 4.6 玩家不打开聊天，就等于没有教练

第一版做出来我自己试了两局，发现小芽的全部能力都在聊天面板里，而我全程没有打开过那个面板。改法是把主入口挪到游戏事件上：开局和关键风险变化时，战斗页底部出现一行短提示，解释收在二级入口里按需展开；玩家出招之后旧提示立刻隐藏，等新局面重新评估。

副作用是提示一多就变成噪音，门控反而比内容更难做：玩家是否在前台、是否已出招、是否已忽略过、本回合是否已提示过、上次提示距今多久、当前风险是否可行动，逐项判断；每局总量、同类只出一次、冷却时间各有上限，老师和军师共用同一份每局配额。

这条通道还有一个口径问题：判断玩家是否掌握某个知识点时，只用他没有被提示过的时候做出的选择（文献里的 assistance dilemma，见第二节）。

#### 4.7 对手交给模型，引擎只列合法行动

题目场景是 PVP，我最初的做法是让引擎的启发式当对手：轻松档随机，标准档优先伤害和治疗，挑战档枚举双方合法行动并比较一回合结果。这一轮改了——**对手的决策交给模型，引擎只负责列出有哪些合法行动。**

改的理由不是「这样显得对手更聪明」——这个类型里决定胜负的是搜索和训练，不是语言能力。上一条结论回答的是「谁更强」，这一轮要解决的是「对面得是个人」：按伤害公式调出来的启发式，出招永远挑不出毛病，也永远不像人。

难度因此改成只控制「给对手多少帮助」，不控制谁在决策：简单档只给合法行动列表，标准档多给一句对手自己教练的建议，挑战档再给出这一回合的枚举分数。对手那个「自己的教练」不是另写一套，而是拿同一份军师推理函数把双方对调后跑出来的（图 7）。

兜底只在四条路径上出现：模型未配置、模型选了列表外的行动、超时（上限 4 秒）、网络错误；四条各有测试，且都必须在没有后端、没有密钥的前提下工作。本次干净跑里四条都没有被真实流量碰到（兜底 0 次），因此并发压力下这条链路的上限如何，我没有测过。

**胜率这一项我没有测出结论。**正常节奏下玩家每回合等待 0 毫秒——对手思考的那一秒被玩家自己的思考时间吸收了；但把 24 局放在一起看，四个格子两边的胜率是 100/100、100/100、66.7/50、50/50，**对手一局都没赢过**。准确的说法是：n=6 而且对手全败，这套对照既不能支持「对手变强了」，也不能支持「打平了」，只能说没有变弱



图 7 本地双人分屏：两侧各一块行动面板、各带一条教练，跑的是同一个推理函数，只是局面的左右对调

的迹象。

同一件事上我自己改错过两次。题目要求军师在对战场景给建议，我的第一版判据却是「只要是对局模式，教练一律不介入」，还把它写成「公平性设计」当亮点——等于把主功能在题目指定的场景里禁用了。第二次改成「对手是真人时闭麦、是电脑时照常」，又不自洽：电脑对手存在的意义就是模拟真人，行为就该一致。最终改成本地对战一律允许教练，只保留线上竞技的闭麦开关；底线不是「整局不说话」，而是「不读取对方待执行的动作」，那条一直没破，也有测试。

## 5 结果

| 项目           | 值                                  |
|--------------|------------------------------------|
| 宠物 / 属性 / 关卡 | 14 只 / 7 种（普通系双向中性） / 5 个          |
| 知识卡          | 93 张（49 张战术卡 + 44 条引擎参考卡）          |
| 自动测试         | npm test: 312 项全部通过，20 个测试文件       |
| 真实模型评测       | 44 条唯一用例，三轮共 132 次调用（不是 132 条独立样本） |
| 检索对照         | 128 条查询 × 4 臂，离线，不调用模型             |
| 平衡矩阵         | 5,796 场 / 398 个臂，规则版本 0.6，本机 185 秒 |
| 对手 agent 实测  | 4 格 × 6 局，543 次真实决策                |

三种角色全部闭环，且都不依赖模型可用——模型不可用时退回规则结论，功能不消失。

用新的相克表重跑 5,796 场，结论是没有哪只宠物被证明明显更强：同属性的六组配对在主要对照里全部未分离；旧规则下唯一统计显著的同类失衡（雷系两只相差 33.3 个百分点、置信区间不重叠）缩到 8.3 个百分点，区间重叠，消失了；九套阵容的胜率极差从 63.0 个百分点收窄到 35.2 个百分点。但矩阵能证明的只是「那条差距消失了、离散度收窄了」，不能证明「属性平衡整体变好」——那需要跨属性对照和消融实验；每格 12 到 60 场，小于约 12 到 15 个百分点的胜率差分不开，玩家侧也不是真人。

检索没有证据表明任何一臂更好，只能说没有证据表明更差。对手 agent 的延迟可用（p50 约 1.05 秒，正常节奏下玩家无感），但 24 局胜负分不开两臂，关于「变强」没有结论。

仓库里另有两个本机可跑完的离线小实验：一个用表格 Q-learning 学「教练何时开口」，一个冻结骨干、只更新 1152 个参数字「该调哪个工具」。它们是这两个窄任务的证据，不能读成「训练了模型」——**生产用的 DeepSeek / 主模型一次都没有被训练过**，线上仍由基座模型规划；前者赢在打扰成本更低而不是教得更好，后者的 16 条测试全是英文二选一。

## 5.1 没有做的

| 项目        | 状态与原因                                                                                        |
|-----------|----------------------------------------------------------------------------------------------|
| 浏览器语音     | 已停用。本想照灵宝那样让教练出个声，接上之后语音模型一直没调好（断句、音色都不对），于是放弃并整体停用；停用之后这一块也没有可观察对象                          |
| 联网 PVP    | 未做。需要服务端权威对局，属于架构问题，不是工程量问题                                                                  |
| 生产主模型权重训练 | 未做。未训练生产 DeepSeek 主模型，线上仍由基座模型规划；只做过一个离线 1152 参数的工具路由头实验（见上文），本机也没有可用的 CUDA 后端               |
| 真人被试相关验收  | 未做。无提示迁移、学习效果观察、分屏双人验收都需要真人被试                                                                |
| 浏览器慢响应验收  | 未做。本机延迟只有 2-4 秒，构造不出可控的慢网                                                                    |
| 独立标注的质量评测 | 未做。128 条检索查询自写自标，绝对数字乐观                                                                      |
| 演示录像      | 未做。本机没有可录制的交互式桌面会话，只生成了截图序列加文字说明； <code>output/demo/</code> 下 21 张截图由无头浏览器驱动真实应用抓取，不是真人操作的录屏 |

接下来优先做三件：给检索加最低分阈值与拒答机制并重测负例拒答率；在看结果之前重新标注评测集；给对手 agent 换一个更强的阵容，让胜负这一项真的能分出差别。

## 6 索引与复现

仓库已发布，公开可克隆：<https://github.com/SeRendizc/pet-game-coach> (276 个文件，无第三方运行时依赖；数字取自 `git ls-files`)。克隆之后 `npm start` 可完整游玩，`npm test` 可复现正文里除模型实验之外的全部结论。

- `npm start`: 启动，默认 127.0.0.1:8765；`npm run test:smoke`: 无头浏览器真打一局
- `npm test`: 312 项自动测试，20 个测试文件（数字随代码增长，以实际运行输出为准）
- `npm run build:knowledge`: 重新生成知识卡；`npm run eval:retrieval`: 检索四臂对照

正文数字的来源：规模与测试数取自 `npm test` 的现场输出；检索对照、工具决策三轮、多步链路核查、平衡矩阵与对手 agent 实测的产物都在 `reports/` 下。宠物数、属性数与知识卡数都能用一行命令现场复算，README 里写明了命令；模型实验需要自己的密钥。